

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/359709878>

Modelo predictivo basado en Machine Learning para la Cadena de Suministro y su influencia en la gestión logística de una empresa de venta de autos

Article in Journal of the ACM · April 2022

CITATIONS

2

READS

2,234

1 author:



[Christian Ovalle](#)

Universidad Tecnológica del Perú

71 PUBLICATIONS 28 CITATIONS

SEE PROFILE

Modelo predictivo basado en Machine Learning para la Cadena de Suministro y su influencia en la gestión logística de una empresa de venta de autos

CHRISTIAN, OVALLE PAULINO

Docente Universitario, Universidad Tecnológica del Perú

RESUMEN

Sin lugar a dudas una de las mayores fortalezas que tiene un país es la producción y exportación de materia prima y también los productos terminados, pero nada de esto sería posible si no se tiene una cadena de suministro optimizada y automatizada en relación a la gestión logística, lo que pretende esta investigación es justamente presentar un modelo de cadena de suministro inteligente a través de un algoritmo predictivo del aprendizaje automático. Luego de la aplicación del modelo predictivo se obtuvo el resultado que las ventas aumentaron según el tipo de automóvil; Sedan 48.60%, Wagon 11.73% y Hatchback 32.52%. Por otro lado, también se observa que hay una marcada relación entre las variables 1 y 2 del 80,2% y también se observa que hay una relación en las variables 1 y 3 del 78,9% y también observamos una relación de las variables 2 y 3 del 82.3%.

Palabras clave: Cadena de suministro • Machine Learning • Gestión logística

1 INTRODUCCIÓN

La cadena de suministro inteligente, se caracteriza por tener un alto nivel de interconexión entre los ámbitos físicos y digitales, donde los sensores de IoT permiten recolectar y transmitir información en tiempo real a lo largo de toda la cadena, donde la analítica de big data, la inteligencia artificial y la computación en la nube hacen posible tomar decisiones de manera simultánea para diferentes procesos [1]. Además, esta llegó gracias a los avances tecnológicos, que permitieron esta gran evolución dentro de la logística; permitiendo el cambio y mejora de este proceso fundamental en las empresas.

Entonces, uno de los eslabones es la tecnología, ya que influye brindando ayuda para garantizar un eficiente flujo de materiales e información [2]. En este sentido, cabe mencionar que actualmente, este cambio ya se ve en diversas empresas ya que la forma de almacenar ha cambiado, a tal punto, de encontrar los almacenes repletos de sensores, con la finalidad de que permitan un mejor almacenamiento y control, lo que influye en la reducción de costos y tiempos. Asimismo, la industria 4.0, dentro de las empresas se enfocan en la digitalización [3].

En este contexto, la inteligencia artificial ha jugado un papel importante, ya que esta es una herramienta tecnológica esencial para la transformación de los procesos logísticos, eso se debe a que la implementación de algoritmos de inteligencia artificial ayudará a mejorar notoriamente las predicciones de demanda; ocasionando una disminución de los errores de predicción, con la finalidad que todo ello influya en la eficiencia de todos los demás procesos, incluyendo a la sostenibilidad financiera de las empresas que participan en la cadena [1].

En la presente investigación se propone implementar un modelo de cadena de suministro inteligente, basado en inteligencia artificial con algoritmos de Machine Learning para la toma de decisiones gerenciales en relación a pedidos, abastecimiento y distribución de materiales de una empresa de venta de autos; ya que puede adaptar procesos en numerosas áreas, incluida la SCM [4]; todo ello, con el fin de mejorar los procesos logísticos mediante la disminución de tiempos, errores y costes; además, de generar ventajas competitivas, evitando que siga en aumento la insatisfacción del cliente, colocándolo como uno de los principales actores para así poder mejorar la confianza y seguridad del mismo.

2 ESTADO DEL ARTE

2.1 Cadena de Suministro Inteligente

Calatayud & Kats [1] nos dicen que, las cadenas de suministros comprenden un conjunto de actividades que abarcan desde el diseño de un producto o servicio, hasta su entrega o prestación a los consumidores finales. Por otro lado, para que se consiga su integración completa, se necesita que

todos los miembros o actores de la cadena de suministro compartan el mismo objetivo con altos esfuerzos de integración conjunta, actuando como si toda la cadena de suministro fuera una entidad monolítica, reflejado el modelo de actor unitario en un marco de cuadrantes conceptuales [5]. Dentro de la empresa estudiada, actualmente, se aplica el siguiente modelo de cadena de suministro.




Figura 1: Cadena de Suministro Inteligente.

Entonces, actualmente, para poder solucionar los problemas en la logística, está ingresando al mercado, una cadena de suministro que implementa las bases de la industria 4.0, la cual es la cadena de suministro inteligentes, que aprovechan los niveles de interacción sin precedentes y que facilitan la colaboración a gran escala; para ayudar a los ejecutivos a evaluar las compensaciones, con la finalidad de que los sistemas inteligentes evalúen innumerables limitaciones y alternativas, permitiendo que las personas asignadas a la toma de decisiones, puedan simular varios cursos de acción [6].

Además, las cadenas de suministro más inteligentes tienen la capacidad analítica de evaluar innumerables alternativas con referencia al proceso de suministro, fabricación y distribución, y la flexibilidad para reconfigurar los flujos a medida que cambian las condiciones; es por ello, que los ejecutivos podrán planificar contingencias y ejecutarlas.

2.2 Inteligencia Artificial

Los avances tecnológicos de la era digital han traído consigo múltiples cambios, mejorando la forma de tomar decisiones por lo que los nuevos modelos de negocios se han visto fuertemente influenciados por los adelantos digitales; a pesar de ello, existe una gran polémica sobre el uso de la inteligencia artificial, debido a que la mayoría de leyes existentes se ha centrado sólo en los seres humanos y la IA, ha traído consigo diversos y novedosos problemas, que los sistemas legales actuales en su gran mayoría están parcial o mínimamente equipados, mientras que otros sencillamente no lo están [7].

Por ende, la inteligencia artificial es una ciencia multidisciplinaria que involucra teorías y modelos de las ciencias cognitivas, lingüística, neurociencias, matemáticas, informática y biología, entre otras; entonces la IA “se basa en el trabajo de varias ramas, como la representación de conocimiento, aprendizaje automático (machine learning), visión artificial, robótica, agentes autónomos, planificación y razonamiento automático, búsqueda y resolución de problemas, y procesamiento de lenguaje natural” [8].

Por último, cabe resaltar que, la inteligencia artificial (IA) abarca una amplia gama de teorías y tecnologías utilizadas para resolver problemas de gran complejidad lógica o algorítmica; a pesar de ser introducida en la década de 1950, muchos métodos de IA se han desarrollado o recientemente con la mejora del rendimiento de los ordenadores [9].

2.3 Machine Learning

Es uno de los principales elementos dentro de la revolución digital que aplica técnicas y algoritmos capaces de aprender a partir de distintas y nuevas fuentes de información, construyendo algoritmos que mejoren de forma autónoma con la experiencia; además, estos algoritmos aprenden de la experiencia (datos) para mejorar el rendimiento en una tarea específica [10].

Todo ello se debe a que es una rama de la inteligencia artificial, que permite a las máquinas aprender, realizar y mejorar las operaciones, haciendo uso de sus conocimientos y la experiencia previa en operaciones adquiridas en forma de datos [11]. Además, con este enfoque se puede procesar y analizar casi automáticamente una gran cantidad de datos de observaciones u otras fuentes [12].

Por otro lado, un enfoque de Machine Learning es transparente “si los procesos que extraen los parámetros del modelo de los datos de entrenamiento generan etiquetas a partir de los datos de prueba, estos pueden ser descritos y motivados por el diseñador del enfoque” [12]; entonces, dicha transparencia depende de la estructura general del modelo, los componentes individuales del modelo, el algoritmo de aprendizaje y cómo es que el algoritmo obtiene la solución específica. Además, los enfoques de ML tienen como objetivo reconocer patrones y extraer conocimientos de datos complejos [13].

Asimismo, en los algoritmos de aprendizaje automático, la regularización para reducir las características adicionales es necesaria para que el coeficiente de regresión sea estable. Además, es posible reducir la lectura de datos, así como los costes de preprocesamiento y cálculo, al mejorar la velocidad del algoritmo y aclarar la cantidad de características que tiene la mayor información, se espera que la interpretación del resultado de la predicción y la explicación [14]. Estos algoritmos, “construyen un modelo basado en datos de muestra, conocidos como datos de entrenamiento, para hacer predicciones o tomar decisiones sin ser programados explícitamente” [15].

Los métodos de aprendizaje automático se han utilizado para resolver complicados problemas prácticos en diferentes áreas y son cada vez más populares en la actualidad. Por ejemplo el sistema energético presenta algunos retos importantes para la gestión de microrredes y energía de las redes inteligentes, tecnologías avanzadas que utilizan sensores y actuadores, IT & C, big data, analítica compleja, etc. Un estudio utilizando el algoritmo de minería de datos “Decision Tree” con un modelo de caja negra basado en Random Forest propone la detección y clasificación de fallos en microrredes [10].

Cabe resaltar, que aplicar Machine Learning, consiste en identificar aquellos grupos de palabras que tienen mayor tendencia a aparecer de forma concurrente a lo largo del texto; esto se logra detectando patrones en una colección de documentos llamada corpus y agrupando las palabras que aparecen en dichos documentos en tópicos [11].

2.4 Aprendizaje Supervisado

Este tipo de aprendizaje está compuesto por algoritmos que intentan encontrar relaciones y dependencias entre un elemento objetivo, con la finalidad de predecir y tomar las decisiones adecuadas siendo su principal objetivo, aprender una función desconocida que toma como parámetros de entrada un grupo de características del conjunto de datos. En este contexto, Manament Solutions nos indica que la información para construir el algoritmo contiene información sobre la característica en estudio, que no está presente en los datos futuros. Por tanto, la información que se quiere predecir o por la que se quiere clasificar una población está disponible en los datos utilizados para construir el modelo [16].

Entonces, se puede afirmar que:

$$\hat{y}=f(x), \forall (x,y) \in D$$

Donde:

X es el vector de variables de entrada

f es la función que conseguimos aprender

\hat{y} es la predicción que devuelve f y que es la más cercana al valor verdadero, y, para todas las instancias x del conjunto de datos “D”

(x,y) indica la salida deseada para cada dato de entrada, dependiendo del tipo puede ser clasificación o regresión.

Entonces, este tipo de aprendizaje aprovecha la información disponible de los datos no etiquetados, junto con la supervisión de los datos etiquetados, para mejorar la eficacia y la generalización de los modelos de aprendizaje automático. Además, para que pueda aprovechar los datos no etiquetados, investiga las restricciones de consistencia para mitigar la brecha dentro y entre los dominios de datos etiquetados y no etiquetados [17]. Asimismo, el objetivo del aprendizaje supervisado es desarrollar modelos de aprendizaje bajo tres tipos de supervisión; los cuales son, supervisión inexacta, supervisión incompleta y supervisión inexacta; dentro de esta última, se encuentra la anotación débil [18].

A pesar de que se ha conseguido un excelente rendimiento mediante aprendizaje supervisado, en la práctica sigue existiendo un problema, el cual es, la creación de etiquetas de entrenamiento es caro [19].

2.5 Aprendizaje No Supervisado

El propósito de este tipo de aprendizaje es explorar los datos y encontrar alguna estructura dentro de ellos; además, en este caso no se dispone en la muestra de construcción la información de una variable que se quiere predecir. Por tanto, en este caso no se dispone de la variable output [16].

El aprendizaje no supervisado es un enfoque especialmente adecuado para identificar la estructura latente inherente a un conjunto de datos; entonces, la fuerza de este enfoque reside en su capacidad para captar la información destacada del conjunto de datos sin la ayuda de una variable objetivo [20]. Es por ello, que en comparación con los métodos supervisados, “los métodos de aprendizaje no supervisado no necesitan etiquetas; así, estos últimos métodos superan la desventaja del aprendizaje supervisado que depende de las etiquetas” [51]; asimismo, “la fuerza de este enfoque reside en su capacidad para captar la información destacada del conjunto de datos sin la ayuda de una variable objetivo” [20]. Entonces, en el aprendizaje no supervisado, la variable objetivo no está disponible y la tarea del algoritmo no está claramente definida, entonces, “el aprendizaje no supervisado permite que el algoritmo funcione por sí mismo para descubrir la información destacada y la estructura latente inherente al conjunto de datos. Los algoritmos más conocidos son la reducción de la dimensionalidad y el análisis de clustering” [20].

3 METODOLOGÍA

En la presente investigación se propone implementar un modelo de cadena de suministro inteligente, basado en inteligencia artificial con algoritmos de Machine Learning para la toma de decisiones gerenciales en relación a pedidos, abastecimiento y distribución de materiales

Para diseñar el modelo de cadena de suministro inteligente, se deben realizar las siguientes etapas: 1) Análisis a detalle de los valores previos obtenidos en meses anteriores, con la finalidad de que sean utilizados como base para implementar los algoritmos en las tres dimensiones a estudiar 2) Rediseño del proceso de logística en base al modelo propuesta, para ello se redefinió los roles existentes, las estrategias de distribución y almacenamiento. 3) Validar el modelo propuesto con la alta gerencia, luego de haber aplicado una prueba base con resultados positivos. 4) Implementar la propuesta, para ello se tuvo que capacitar al personal con la finalidad de que los colaboradores incluyan los datos o valores necesarios para que los algoritmos predigan datos más exactos con relación pasen los meses. Por otro lado, dentro del modelo de cadena de suministro inteligente, en relación al uso de Machine Learning, se basará en el siguiente proceso para su aplicación: 1) Obtener los datos necesarios para realizar una predicción en las tres dimensiones planteadas (Pedidos, Abastecimiento y Distribución de materiales). 2) Preparar los datos obtenidos y en base a ello, seleccionar el algoritmo de Machine, dentro de las cuáles se emplearán, algoritmos de regresión o predicción y de agrupamiento. 3) Entrenar el modelo y luego de ello probar el modelo a ver si cumple las funciones asignadas a cada algoritmo. 4) Aplicar y validar el modelo para que pueda emplearse de manera correcta en el modelo propuesto de cadena de suministro.

Además, cabe resaltar, que dentro del modelo, se busca lograr los siguientes requerimientos estratégicos de información:

Algoritmo de Predicción	Requerimientos estratégicos de Información	Fines
Regresión logística	¿Cuántos materiales de lectura nos van a solicitar por trimestre?	Servirá para reducir la incertidumbre de la demanda en la cadena de suministro; también se empleará para la previsión de la demanda. Todo ello, con la finalidad de que este tenga una base más sólida y una predicción más exacta
	¿Qué materiales de lectura los clientes seguirán necesitando?	Servirá para predecir las decisiones que tomarán los clientes según un histórico que permitirá anteponerse ante una futura demanda de materiales; asimismo, se tomará en cuenta el número y las cancelaciones

		de pedidos para las predicciones futuras.
Regresión lineal	¿Qué tipo de material de lectura vamos a solicitar a los proveedores?	Según las predicciones que nos brindará el algoritmo de regresión logística se podrá predecir qué tipo de materiales se va a solicitar a los proveedores, con el fin de tener los productos en el momento adecuado y enviarlos puntualmente a cada lugar de distribución.
Algoritmo de Agrupamiento	Requerimientos estratégicos de Información	Fines
KMeans	¿Qué tipo de materiales de lectura solicitarán según cada sede de distribución?	Mediante el agrupamiento, la distribución por sede se realizará de manera adecuada con la finalidad de evitar el desabastecimiento y brindar una distribución equitativa a todos.
	¿Qué tipo de materiales de lectura solicitarán según cada ciudad donde se distribuyen?	Según la demanda prevista para cada ciudad, se distribuirá por cada agrupamiento, con la finalidad de evitar el desabastecimiento.

Asimismo, con relación a los datos, la misma empresa actualmente no gestiona sus datos de manera adecuada; es por ello, que se hará una limpieza a los datos y total organización empleando Microsoft Excel y Power BI para la visualización de los mismos. Además, para el modelo donde se emplearán los algoritmos anteriormente mencionados, se empleará la herramienta Azure.

El diseño del modelo de cadena de suministro inteligente tendrá la capacidad analítica de evaluar innumerables alternativas con referencia al proceso de abastecimiento, pedidos y distribución de materiales, y la flexibilidad para reconfigurar los flujos a medida que cambian las condiciones; es por ello, que los ejecutivos podrán planificar contingencias y ejecutarlas [6].

Todo ello, con la finalidad de que la gerencia pueda tomar decisiones basadas en la analítica de datos y la aplicación de algoritmos de Machine Learning implementados en la cadena de suministro. Por último, dentro del modelo de cadena de suministro inteligente, se consideraron los siguientes componentes:

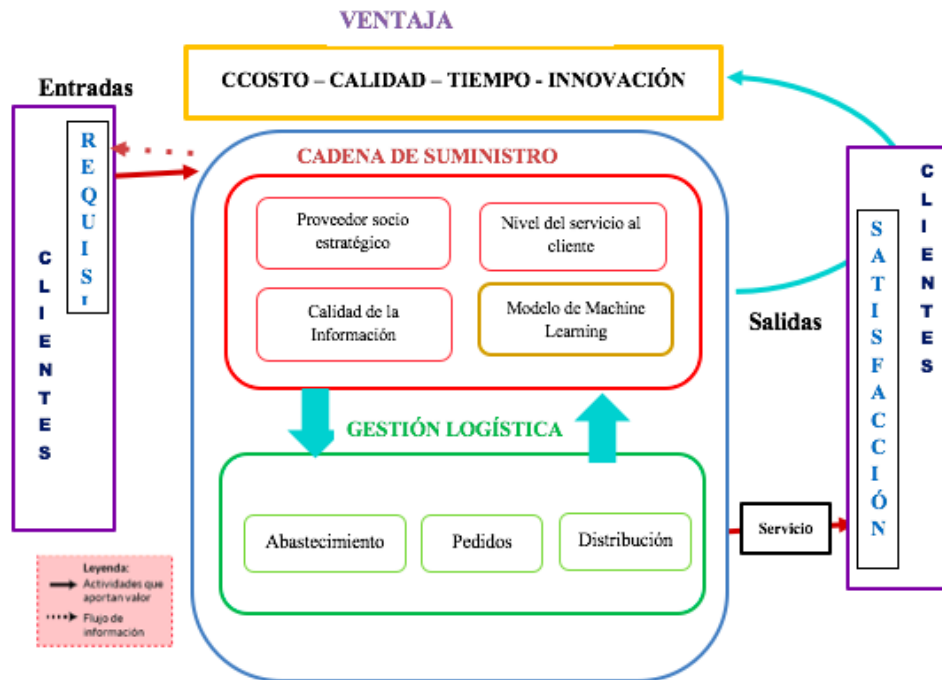


Figura 2: Módulo de Cadena de Suministro Inteligente

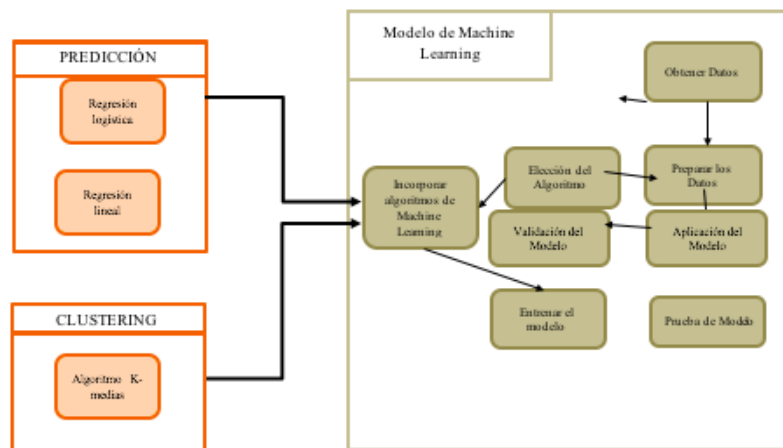


Figura 3: Esquema de modelo de Machine Learning

Con relación al modelo, en el modelo supervisado, la técnica aplicada es la regresión, con la finalidad de predecir el valor de la variable de precio según el resto de variables dependientes (marca, tipo de motor, tipo de carrocería, entre otros).

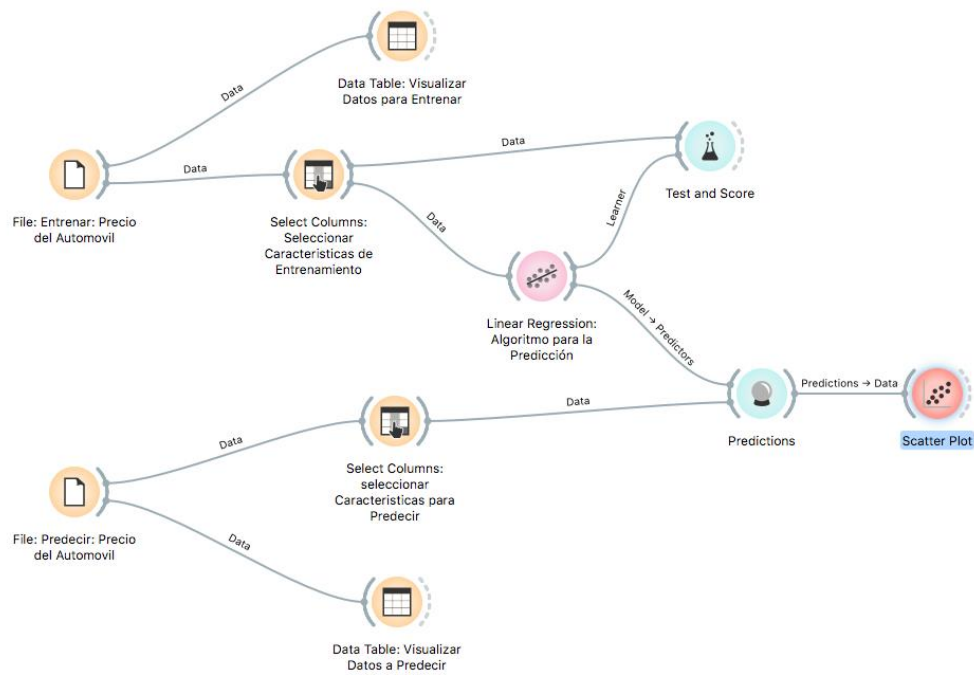


Figura 4: Modelo Predictivo aplicando la técnica de regresión en el Aprendizaje Supervisado

Por otro lado, en el aprendizaje no supervisado se aplica la técnica clustering, la cuál identificará los distintos grupos o segmentos, los cuáles serán agrupado por la marca del carro.



Figura 5: Modelo aplicando la técnica clustering o agrupamiento jerárquico en el Aprendizaje No Supervisado

4 RESULTADOS

4.1 Tecnología a implementar

La empresa se dedica al rubro comercial específicamente a la venta de autos de distintas marcas, si bien es cierto, la empresa actualmente maneja una base de datos básica en Excel, pero no es compartida con el resto de la empresa solo el área comercial tiene acceso a ello. Es por ello que luego, de realizar un análisis, se identificó la necesidad principal la cuál sería alojar los datos en la nube para que las distintas áreas de la empresa puedan recolectar datos con relación a sus variables que posiblemente pueden interferir o intervenir en futuras predicciones de ventas y así se logre realizar más detallado el modelo de Inteligencia Artificial.

4.2 Definición del conjunto de datos y aplicación de Estadística Descriptiva

El conjunto de datos que nos brindó la empresa fue con referencia a los autos vendidos en el segundo semestre del año 2020, entre los cuáles resaltan las marcas Chevrolet, Toyota, Nissan, entre otros. Esta data, se subdividía en marca de auto, tipo de carrocería, base de ruedas, tipos de motor, caballos de fuerza, revoluciones minuto, kilómetros por galón y precio.

Con la finalidad de que se entienda un poco mejor la base de datos se decidió ordenarla por marca y tipo de carrocería.




Figura 5: Aprendizaje Supervisado - Técnica de Regresión Análisis estadístico Inferencial




Figura 6: Distribución Marca- Tipo de carrocería

Con relación al tipo de carrocería Convertible, se vendieron 2 carros Alfa – Moreno, 1 Mercedes – Benz y un Voikswagen. Por otro lado, en la carrocería Hardtop, se vendieron 2 autos Mercedes – Benz, 2 Porshe y 2 Volkswagen. Luego de ello, la carrocería Sedan, se vendió 1 auto Alfa – Romero, 5 Dodge, 6 Honda, 1 Isuzu, 1 Mercury, 8 Mitsubishi, 5 Nissan, 3 Plymouth, 1 Porsche, 3 Saab, 2 Saburu, 13 Toyota y 1 Volkswagen.

Asimismo, en la carrocería Sedan se vendieron 4 autos Audi, 8 BMW, 1 Chevrolet, 2 Jaguar, 7 Mazda, 4 Mercedes – Benz, 3 Mitsubishi, 9 Nissan, 6 Pougot, 2 Plymouth, 3 Saab, 5 Subaru, 9 Toyota, 8 Volkswagen y 7 Volvo. Por último, de la carrocería Wagon, se vendió 1 auto Audi, 1 Honda, 3 Nissan, 4 Peugeot, 1 Plymouth, 3 Subaru, 4 Toyota, 1 Volkswagen y 3 autos Volvo.

Con la finalidad de sintetizar dicha información se procedió a realizar una tabla, en la cual se podrá observar la totalidad de cada carrocería con relación a las distintas marcas de autos que se venden en la empresa. Asimismo, se presentará el porcentaje de venta que pertenece cada tipo de carrocería.

Tabla 1. Porcentaje de venta según el tipo de carrocería

1. Tipo de carrocería	2. Cantidad vendida	3. Porcentaje de total de ventas
4. Convertible	5. 5	6. 2.79%
7. Hardtop	8. 6	9. 3.35%
10.Hatchback	11.60	12.33.52%
13.Sedan	14.87	15.48.60%
16.Wagon	17.21	18.11.73%




Figura 7: Porcentaje total de ventas

4.3 Análisis estadístico inferencial

Se realizó un análisis estadístico inferencial, donde se obtuvieron resultados óptimos con relación del Machine Learning para la Cadena de Suministro y su influencia en la gestión logística.

Donde se observa existe muy buena confiabilidad elaborado para el recojo de la información de la presente investigación, de las variables que son la variable Machine Learning del 81,5%, la variable Cadena de Suministro del 82,3% y la variable gestión logística del 77,2%.

Alfa de Cronbach	Alfa de Cronbach basada en los elementos tipificados	VARIABLES
81,5%	78.7%	V1: MACHINE LEARNING
82,3%	81.9%	V2: CADENA DE SUMINISTRO
77,2%	77.0%	V3: GESTION LOGISTICAL

Fig. 4 Alfa de Cronbach

Se observa en la columna sig. Kolmogorov-Smimov de todos son menores que 0.05, lo cual se rechaza la hipótesis Nula. Concluimos que la variable 1 Machine Learning, la variable 2 Cadena de Suministro y la variable 3 gestión logística no se distribuyen en forma normal. Por tanto, aplicaremos la prueba estadística no paramétrica de escala ordinal de rho de Spearman.

	Kolmogorov-Smirnova		
	Estadístico	gl	Sig.
V1: MACHINE LEARNING	0,235	30	0,001
V2: CADENA DE SUMINISTRO	0,213	30	0,002
V3: GESTIÓN LOGÍSTICA	0,287	30	0,007

Fig. 5 la columna sig. Kolmogorov-Smimov.

Finalmente se observa que hay una marcada relación entre las variables 1 y 2 del 80,2% y también se observa que hay una relación en las variables 1 y 3 del 78,9% y también observamos una relación de las variables 2 y 3 del 82.3%.

Matriz de Correlaciones

			V1: MACHINE LEARNING	V2: CADENA DE SUMINISTRO	V3: GESTIÓN LOGÍSTICA
Rho de Spearman	V1: MACHINE LEARNING	Coeficiente de correlación	1,000	0,802	0,789
		Sig. (bilateral)	.	0,017	0,017
		N	30	30	30
	V2: CADENA DE SUMINISTRO	Coeficiente de correlación	0,802	1,000	0,823
		Sig. (bilateral)	0,017	.	0,020
		N	30	30	30
	V3: GESTIÓN LOGÍSTICA	Coeficiente de correlación	0,789	0,823	1,000
		Sig. (bilateral)	0,017	0,020	.
		N	30	30	30

Fig. 6 Rho de Spearman.

REFERENCIAS

- [1] A. Calatayud and R. Katz, "Cadena de suministro 4.0: Mejores prácticas internacionales y hoja de ruta para América Latina," *Cadena Suminist. 4.0 Mejor. prácticas Int. y hoja ruta para América Lat.*, 2019, doi: 10.18235/0001956.
- [2] Y. Leal, "Gestión Logística De Materiales En La Industria Petrolera Venezolana," *Rev. Enfoques*, vol. 2, no. 5, pp. 16–34, 2018, doi: 10.33996/revistaenfoques.v2i5.27.
- [3] A. Calatayud and M. F. Millan, "ALC 2030: Construyendo las cadenas de suministro del futuro," *ALC 2030 Construyendo las cadenas Suminist. del Futur.*, 2019, doi: 10.18235/0001969.
- [4] R. Toorajipour, V. Sohrabpour, A. Nazarpour, P. Oghazi, and M. Fischl, "Artificial intelligence in supply chain management: A systematic literature review," *J. Bus. Res.*, vol. 122, no. September 2020, pp. 502–517, 2021, doi: 10.1016/j.jbusres.2020.09.009
- [5] A. Sener, M. Barut, A. Oztekin, M. Y. Avcilar, and M. B. Yildirim, "The role of information usage in a retail supply chain: A causal data mining and analytical modeling approach," *J. Bus. Res.*, vol. 99, pp. 87–104, Jun. 2019, doi: 10.1016/j.jbusres.2019.01.070.
- [6] K. Butner, *The smarter supply chain of the future*, vol. 38, no. 1. 2010.
- [7] A. K. Chávez Valdivia, "Redesigning the ownership of artworks: Artificial and robotic intelligence," *Rev. Chil. Derecho y Tecnol.*, vol. 9, no. 2, pp. 153–185, 2021, doi: 10.5354/0719-2584.2020.57674.
- [8] C. A. Paz, "Legal challenges for artificial intelligence in Chile," *Rev. Chil. Derecho y Tecnol.*, vol. 9, no. 2, pp. 257–290, 2021, doi: 10.5354/0719-2584.2020.54489.
- [9] P. Ezanno *et al.*, "Research perspectives on animal health in the era of artificial intelligence," *Vet. Res.*, vol. 52, no. 1, pp. 1–15, 2021, doi: 10.1186/s13567-021-00902-4.
- [10] M. Vázquez-Marrufo, E. Sarrias-Arrabal, M. García-Torres, R. Martín-Clemente, and G. Izquierdo, "A systematic review of the application of machine-learning algorithms in multiple sclerosis," *Neurologia*, no. xxxx, 2021, doi: 10.1016/j.nrl.2020.10.017.
- [11] D. J. Benavides, P. Arévalo, L. G. González, and L. Hernández, "Method of monitoring and detection of failures in PV system based on machine learning," *Rev. Fac. Ing. Univ. Antioquia*, no. 102, pp. 26–43, 2021, doi: 10.17533/udea.redin.20200694.
- [12] S. J. Nawaz, S. K. Sharma, S. Wyne, M. N. Patwary, and M. Asaduzzaman, "Quantum Machine Learning for 6G Communication Networks: State-of-the-Art and Vision for the Future," *IEEE Access*, vol. 7, no. Ml, pp. 46317–46350, 2019, doi: 10.1109/ACCESS.2019.2909490.
- [13] R. Roscher, B. Bohn, M. F. Duarte, and J. Garcke, "Explainable Machine Learning for Scientific Insights and Discoveries," *IEEE Access*, vol. 8, pp. 42200–42216, 2020, doi: 10.1109/ACCESS.2020.2976199.
- [14] M. Garbulowski *et al.*, "R.ROSETTA: an interpretable machine learning framework," *BMC Bioinformatics*, vol. 22, no. 1, pp. 1–18, 2021, doi: 10.1186/s12859-021-04049-z.
- [15] Y. Matsuzaka and Y. Uesawa, "A molecular image-based novel quantitative structure-activity relationship approach, deepsnap-deep learning and machine learning," *Curr. Issues Mol. Biol.*, vol. 42, pp. 455–472, 2021, doi: 10.21775/cimb.042.455.
- [16] M. Kim *et al.*, "Machine learning models to identify low adherence to influenza vaccination among Korean adults with cardiovascular disease," *BMC Cardiovasc. Disord.*, vol. 21, no. 1, pp. 1–8, 2021, doi: 10.1186/s12872-021-01925-7..
- [17] Manament Solutions, "Machine Learning una pieza clave en la transformación de los modelos de negocio," 2018, [Online]. Available: <https://www.managementsolutions.com/sites/default/files/publicaciones/esp/machine-learning.pdf>.
- [18] D. Yang *et al.*, "Federated semi-supervised learning for COVID region segmentation in chest CT using multi-national data from China, Italy, Japan," *Med. Image Anal.*, vol. 70, p. 101992, 2021, doi: 10.1016/j.media.2021.101992.
- [19] Q. Gao and X. Shen, "Styhighnet: Semi-supervised learning height estimation from a single aerial image via unified style transferring," *Sensors*, vol. 21, no. 7, pp. 1–15, 2021, doi: 10.3390/s21072272.
- [20] C. Lee, "Predicting land prices and measuring uncertainty by combining supervised and unsupervised learning," *Int. J. Strateg. Prop. Manag.*, vol. 25, no. 2, pp. 169–178, 2021, doi: 10.3846/ijspm.2021.14293

